TransNovel 풀파이프라인 비용 분석

중국어 웹소설 1,500,000자 1회 처리 기준 (번역 + 설정집 생성)

작성일 2026-04-30 · 리전 ap-northeast-2 (Seoul) · Vercel Pro + AWS + Gemini API

핵심 요약

1편당 변동비 (Per-Novel)

≈ $9.7 — $42

모델 선택에 따라 4배 차이. Gemini API가 90% 이상 차지

월 고정비 (인프라)

≈ $182 / 월

RDS + Proxy + Vercel Pro + 모니터링. 작품 수와 무관

> **핵심 메시지** 1.5M자는 **한 번의 거대 호출**이 아니라 **약 500화 × ~3,000자**로 처리됩니다 (대부분 챕터가 청크 임계값 41,000자 미만이라 1챕터 = 1 API 호출). 따라서 변동비는 **총 호출 수 × 호출당 토큰 단가**로 결정되며, AWS 비용은 거의 무시 가능한 수준이고 **Gemini API 단일 비용이 지배적**입니다.

1. 워크로드 산정 (Pipeline Sizing)

입력 가정

항목	값	근거
총 원문 분량	1,500,000자	요청 입력값
평균 챕터 길이	~3,000자	중국 웹소설 일반치 (200~600화 작품의 중간값)
총 챕터 수	~500화	1,500,000 ÷ 3,000
CJK 비율	~95%	중문 원문
토큰/문자 환산	1.4375 토큰/자	`0.95×1.5 + 0.05×0.25` (translate.ts:291)
총 입력 콘텐츠 토큰	≈ 2,156,250	1,500,000 × 1.4375

번역 파이프라인 호출 수

```
청크 임계값 = max(8000, 59000토큰 ÷ 1.4375) ≈ 41,043자/청크
3,000자 챕터 < 41,043자 → 챕터당 단일 호출 (translateSingleChapter)
번역 API 호출 수 = 500 (챕터당 1회) × 1.15 (재시도/실패 보정) ≈ 575회
```

설정집 생성 호출 수

```
CHAPTERS_PER_BATCH = 5 (bible-generator.ts:29)
배치 수 = 500 ÷ 5 = 100 배치
설정집 API 호출 수 = 100 × 1.15 (재시도) ≈ 115회
```

2. Gemini API 비용 (지배적 비용)

모델 우선순위 (client.ts:140)

- **1순위:** `gemini-3-flash-preview` — 대부분의 호출이 여기서 처리됨
- **2순위:** `gemini-2.5-flash` — 503/overload 시 폴백
- **3순위:** `gemini-2.0-flash` — 위 두 모델 모두 실패 시

호출당 토큰 (번역)

구성	토큰	비고
시스템 프롬프트 (역할/가이드)	~1,500	고정
작품 메타 + 필터링된 용어집/인물	~800	filterContextForContent 적용
원문 콘텐츠 (3,000자)	~4,313	3000 × 1.4375
총 입력	**~6,613**	
출력 (번역)	**~4,313**	한국어는 입력과 비슷한 토큰 수

호출당 토큰 (설정집 1배치 = 5화)

구성	토큰	비고
지시문 + JSON 스키마	~500	buildBibleAnalysisPrompt
5화 원문 (15,000자)	~21,563	15000 × 1.4375
총 입력	**~22,063**	
출력 (JSON)	**~3,000**	maxOutputTokens=16384이지만 실측 ~1.6~3.4K

총 토큰 (재시도 1.15배 보정 포함)

단계	호출 수	총 입력 토큰	총 출력 토큰
번역 (500화 × 1.15)	575	3,802,475	2,479,975
설정집 (100배치 × 1.15)	115	2,537,245	345,000
합계	**690**	**6,339,720**	**2,824,975**

모델별 가격 시나리오

Gemini Preview 모델 가격은 정식 출시 후 변동될 수 있으므로 **3가지 시나리오**로 제시합니다.

시나리오	가정 모델/단가	입력 비용	출력 비용	합계 (USD)	합계 (KRW)
A. 낙관 (2.0-flash 단가)	$0.10/M in · $0.40/M out	$0.63	$1.13	$1.76	₩2,500

B. 표준 (2.5-flash 단가)	$0.30/M in · $2.50/M out	$1.90	$7.06	$8.96	₩12,700
C. 보수적 (Pro급 가정)	$1.25/M in · $10.00/M out	$7.92	$28.25	$36.17	₩51,000

> **현실적 추정**: 코드의 1순위가 `gemini-3-flash-preview` 이므로 **시나리오 B에 가까운 ~$9/편**이 가장 가능성 높은 값입니다.
> 시나리오 A는 폴백이 자주 일어날 때, C는 신모델 프리뷰 가격이 Pro 수준으로 책정됐을 때입니다.
> 환율 ₩1,410/USD 적용. 1 USD ≈ 1,410 KRW (2026-04 기준 추정).

3. AWS 인프라 비용

아키텍처 구성 (terraform/lambda.tf, eventbridge.tf, rds.tf)

- **Translation Worker Lambda**: 1,536 MB · 900s timeout · 동시성 50 (variables.tf:67-83)
- **Bible Worker Lambda**: 1,024 MB · 900s timeout · 동시성 10 · batch_size 5
- **Health Checker Lambda**: 512 MB · 300s timeout · EventBridge 4종 (5분/15분/1시간/1일)
- **SQS 큐 3종**: translation, bible, dlq · 가시성 960s
- **RDS PostgreSQL 15**: `db.t4g.large` · 20GB gp3 · Single-AZ · Performance Insights · Enhanced Monitoring 60s
- **RDS Proxy**: 연결 풀링용
- **Secrets Manager**: database, gemini, auth (3 secrets)
- **VPC**: 2 public + 2 private subnet

3-1. 변동비 (1.5M자 1편당)

Translation Worker Lambda

```
호출 수 = 575 (재시도 포함)
평균 실행 시간 = 45s (Gemini API 응답 + DB write)
GB-초 = 575 × 45 × 1.536 = 39,744 GB-s
가격 (Seoul) = $0.0000166667/GB-s
비용 = 39,744 × $0.0000166667 ≈ $0.66
요청 비용 = 575 × $0.20 / 1,000,000 ≈ $0.0001 (무시)
```

Bible Worker Lambda

```
호출 수 = 115
평균 실행 시간 = 30s
GB-초 = 115 × 30 × 1.024 = 3,533 GB-s
비용 = 3,533 × $0.0000166667 ≈ $0.06
```

SQS

```
메시지 수 = 575 + 115 = 690
연산 수 (send + receive + delete) = 690 × 3 ≈ 2,070
비용 = 2,070 × $0.40 / 1,000,000 ≈ $0.001
```

데이터 전송 (Lambda → Gemini API egress)

```
총 토큰 ~9.2M ≈ ~30~40 MB 페이로드 (요청+응답)
egress 가격 = $0.09/GB → ≈ $0.004
```

CloudWatch Logs (운영 로그 모드)

```
평균 1MB/invocation × 690 = ~700 MB
ingestion = 0.7 GB × $0.50 = $0.35
storage = $0.03/GB-월 × 0.7 GB = $0.02
```

3-1 변동비 합계

항목	USD/편	KRW/편
Translation Lambda	$0.66	₩930
Bible Lambda	$0.06	₩85
SQS	$0.001	₩2
Egress (Gemini)	$0.004	₩6
CloudWatch Logs	$0.37	₩520
AWS 변동비 소계	**$1.10**	**₩1,550**

3-2. 고정비 (월 단위, 작품 수 무관)

항목	스펙	USD/월
RDS db.t4g.large	2vCPU/8GB · Single-AZ · 24×30h × $0.184/h	$132.48
RDS Storage (gp3)	20 GB × $0.115	$2.30
RDS 백업	7일 보관, 무료 한도 내 가정	$0.00
Performance Insights	7일 보관 (Free tier)	$0.00
Enhanced Monitoring	60s 간격	$1.50
RDS Proxy	2 vCPU × $0.015/h × 720h	$21.60
Health Checker Lambda	5분/15분/1시간/1일 스케줄 · ~12K invoke/월	$0.55
EventBridge 규칙	4 rules · 무료 한도 내	$0.00
NAT Gateway	1× $0.045/h × 720h (private subnet → 외부)	$32.40
Secrets Manager	3 secrets × $0.40	$1.20
CloudWatch Alarms	~6 alarm × $0.10	$0.60
CloudWatch Logs (보관)	~5GB × $0.03	$0.15
VPC/기타 (라우팅, EIP 등)	고정 IP 1개 등	$3.65
AWS 고정비 소계		**$196.43**
Vercel Pro	$20/월 (포함량 내 운영)	$20.00

월 고정비 합계	**$216.43 ≈ ₩305,000**

> **주의 — NAT Gateway**: `vpc.tf` 에 NAT가 있다면 한 달 ~$32, 만약 RDS Proxy + Lambda를 모두 public subnet 또는 VPC 엔드포인트로 라우팅한다면 NAT 없이도 가능합니다. 실제 설정에 따라 ±$30/월 변동될 수 있습니다.

4. 총 비용 정리

1.5M자 1편 처리 (변동비)

구성	시나리오 A (낙관)	시나리오 B (표준, 권장)	시나리오 C (보수적)
Gemini API (번역 + 설정집)	$1.76	$8.96	$36.17
AWS (Lambda + 부속)	$1.10	$1.10	$1.10
1편당 합계 (USD)	**$2.86**	**$10.06**	**$37.27**
1편당 합계 (KRW)	**₩4,030**	**₩14,200**	**₩52,500**

월별 총비용 시뮬레이션 (작품 수 × 1.5M자 기준)

월간 작품 수	변동비 (B 시나리오)	고정비	월 합계 (USD)	월 합계 (KRW)
1편	$10.06	$216.43	$226.49	₩319,000
10편	$100.60	$216.43	$317.03	₩447,000
50편	$503.00	$216.43	$719.43	₩1,014,000
100편	$1,006.00	$216.43	$1,222.43	₩1,724,000

5. 최적화 포인트

비용 비중 (시나리오 B 기준)

- **Gemini API: 89%** — 절대 지배적
- **AWS Lambda: 7%** — 거의 무시 가능
- **CloudWatch Logs: 4%**

실효 절감 가능 항목

항목	현재	최적화 시	효과
모델 폴백 순서	3-flash-preview 우선	품질 허용 시 2.0-flash 우선	Gemini 비용 ~80% 절감 ($9 → $2)
설정집 배치 사이즈	5화/배치	10화/배치 (테스트 필요)	Bible 호출 50% 감소, 비용 ~$0.5/편 절감
프롬프트 필터링	filterContextForContent 적용	이미 적용됨	~30% 입력 토큰 절감 중
RDS 인스턴스	db.t4g.large ($132/월)	db.t4g.medium ($66/월)	$66/월 절감 (성능 검증 필요)

RDS Proxy	상시 가동 ($22/월)	Lambda 동시성 줄이고 직접 연결	$22/월 절감 (커넥션 한도 주의)
NAT Gateway	상시 ($32/월)	VPC Endpoint로 대체	$25~30/월 절감
CloudWatch 로그 보관	14일	7일 + 운영 로그만	~$0.2/편 절감

6. 참고 사항

- **재시도 보정 1.15배**: CONTENT_BLOCKED, 503/overload, 빈 응답 등으로 인한 실측 평균. 안전 우회 프롬프트 동작 시 일부 호출은 2배 토큰 소비.
- **Gemini Preview 모델 가격**: 공개되지 않은 경우 GA 모델(`gemini-2.5-flash`) 가격을 사용. 정식 출시 후 가격 재검토 필요.
- **RDS Free Tier**: 신규 계정 12개월간 db.t3.micro 750h/월 무료 — 본 인프라(t4g.large)는 Free Tier 대상 아님.
- **병렬도**: Translation 동시성 50, Bible 10. 1.5M자 1편을 단일 작업으로 돌리면 wall-clock 약 30~60분 소요 예상 (실제 비용은 동시성과 무관).
- **CONTENT_BLOCKED 폴백**: 안전 우회 프롬프트로 재시도 시 추가 호출 1~3회/문제챕터 발생. 메모리 기록상 64화 사례 참고.

TransNovel 비용 분석 · 코드 기준: client.ts MODEL_PRIORITY, translate.ts TARGET_CHUNK_TOKENS, bible-generator.ts CHAPTERS_PER_BATCH, terraform/lambda.tf, terraform/rds.tf, terraform/eventbridge.tf